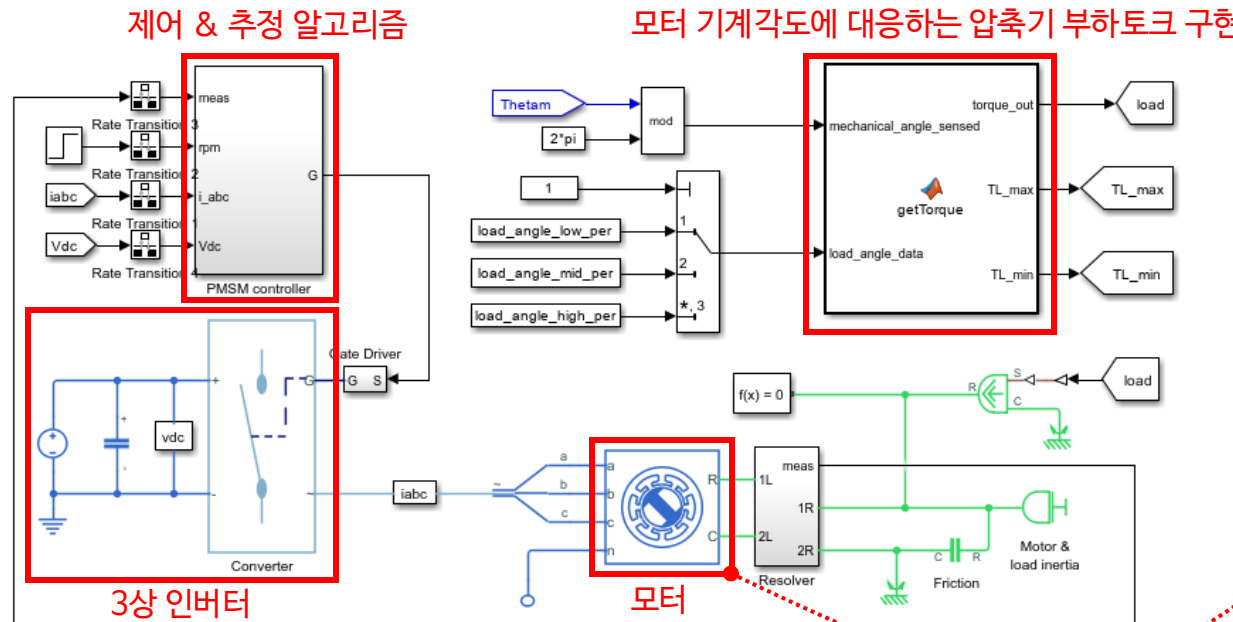
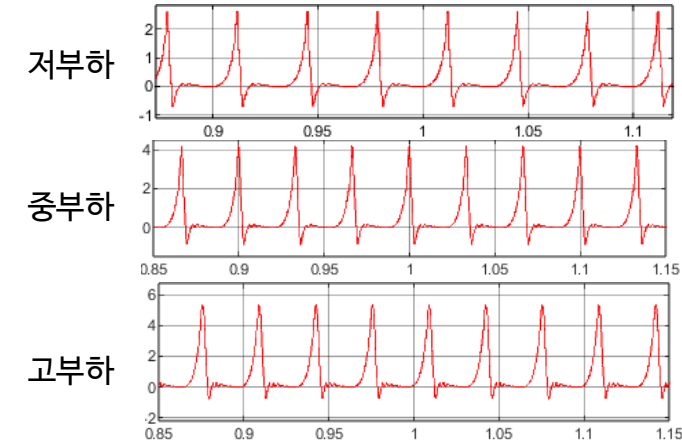


# 시뮬레이션 환경 구축

## • MATLAB/SIMULINK의 Simscape 기반 환경 구축

- ‘Three-Phase PMSM Traction Drive’ 예제를 기반으로 필요한 부분 추가/수정하여 구축
- 모터 전압포화 이슈로 인해 DC link 전압을 3배 증가시켜 진행(부록1 참고)



$$\begin{aligned}
 J_m &= 0.000345 \\
 B_m &= J/100 \\
 \phi_f &= 0.137 \text{ [Vs]} \\
 L_d &= 101.56 \text{ [mH]} \\
 L_q &= 177.75 \text{ [mH]} \\
 R_s &= 6.925 \text{ } [\Omega] \\
 \text{Max RPM} &= 4500 \\
 \text{poles} &= 6
 \end{aligned}$$

# 신규 토크제어 방법

## • 인공지능망 기반 부하토크 실시간 학습 및 보상

### • 시스템 모델링

$$\dot{\omega}_m(t) = -\frac{B_m}{J_m}\omega_m(t) + \frac{1}{J_m}T_e(t) - \frac{1}{J_m}T_L(t)$$

상태공간  
표현

$$\dot{x}(t) = Ax(t) + Bu(t) + g(t),$$

$$y(t) = Cx(t)$$

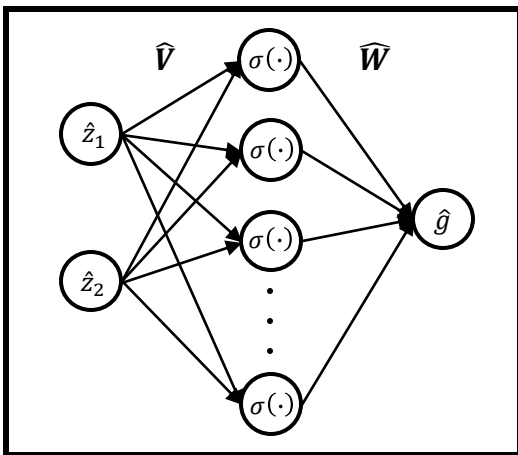
$$\text{where, } x(t) = \omega(t), u(t) = T_e(t), g(t) = -T_L(t)/J_m,$$

$$A = -\frac{B_m}{J_m}, B = \frac{1}{J_m}, C = 1$$

부하토크를 포함한 불확실한 항을  
인공지능망으로 모델링

### • 인공지능망 기반 상태 관측기 설계

$g(t)$ 를 학습 & 추정하는 인공지능망



$$\hat{\dot{x}}(t) = A\hat{x}(t) + Bu(t) + \hat{g}(t),$$

$$\hat{y}(t) = C\hat{x}(t)$$

$$\text{where, } \hat{g}(t) = \widehat{W}\sigma(\widehat{V}\hat{z}), \hat{z} = [\theta_m \quad \hat{x}]^T$$

$$\dot{\widehat{W}} = -\eta_1(\tilde{y}^T C A^{-1})^T \hat{\sigma}^T - \rho_1 ||\tilde{y}|| \widehat{W}$$

$$\dot{\widehat{V}} = -\eta_2 \left( \tilde{y}^T C A^{-1} \widehat{W} (\mathbf{I}_h - \mathbf{\Pi}) \right)^T \hat{z}^T - \rho_2 ||\tilde{y}|| \widehat{V}$$

$$\text{where, } \tilde{y} = y - \hat{y}, \hat{\sigma} = \tanh(\widehat{V}\hat{z}),$$

$\mathbf{I}_h = h$  차원의 단위 행렬,

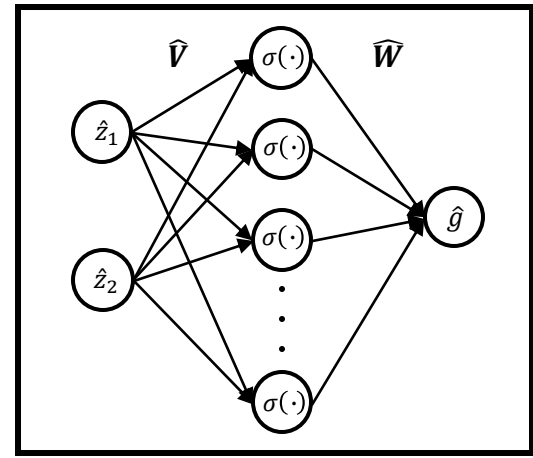
$h$ : hidden layer의 node 수,  $\mathbf{\Pi} = \text{diag}(\hat{\sigma})^2$ ,

$\eta$ : learning rate,  $\rho$ : damping factor

- 불확실한 항  $g(t)$ 를 인공지능망 기반 학습을 통해 추정
- 이 인공지능망은 하나의 은닉층과  $h$ 개의 노드로 구성됨
- $\sigma$ 는 활성화함수로 hyperbolic tangent을 사용함
- $\widehat{W}, \widehat{V}$ 는 가중치 행렬으로, 학습법칙을 통해 온라인으로 자동으로 찾아짐

# 신규 토크제어 방법

- 인공지능 기반 부하토크 실시간 학습 및 보상
  - 인공지능 기반 상태 관측기 수렴성 분석(도출과정은 부록2 참고)
    - Lyapunov function  $L$  정의 및 이의 미분값 확인



$$L = \frac{1}{2} \tilde{x}^T P \tilde{x} + \frac{1}{2} \text{tr}(\tilde{W}^T \tilde{W}) + \frac{1}{2} \text{tr}(\tilde{V}^T \tilde{V})$$

$$A^T P + P A = -Q, C A^{-1} := \alpha$$

$$P, Q > 0$$

$$\dot{L} = -\frac{1}{2} \tilde{x}^T Q \tilde{x} + \tilde{x}^T P (\tilde{W} \tilde{\sigma} + \tilde{W} \tilde{\sigma}) + \text{tr} \left( \tilde{W}^T \left( \eta_1 \alpha \tilde{\sigma}^T + \rho_1 \|\tilde{y}\| (W_M + \tilde{W}) \right) \right) + \text{tr} \left( \tilde{V}^T \left( \eta_2 \left( \tilde{y}^T \alpha \tilde{W} (\mathbf{I}_h - \Pi) \right)^T \hat{z}^T + \rho_2 \|\tilde{y}\| (V_M - \tilde{V}) \right) \right)$$

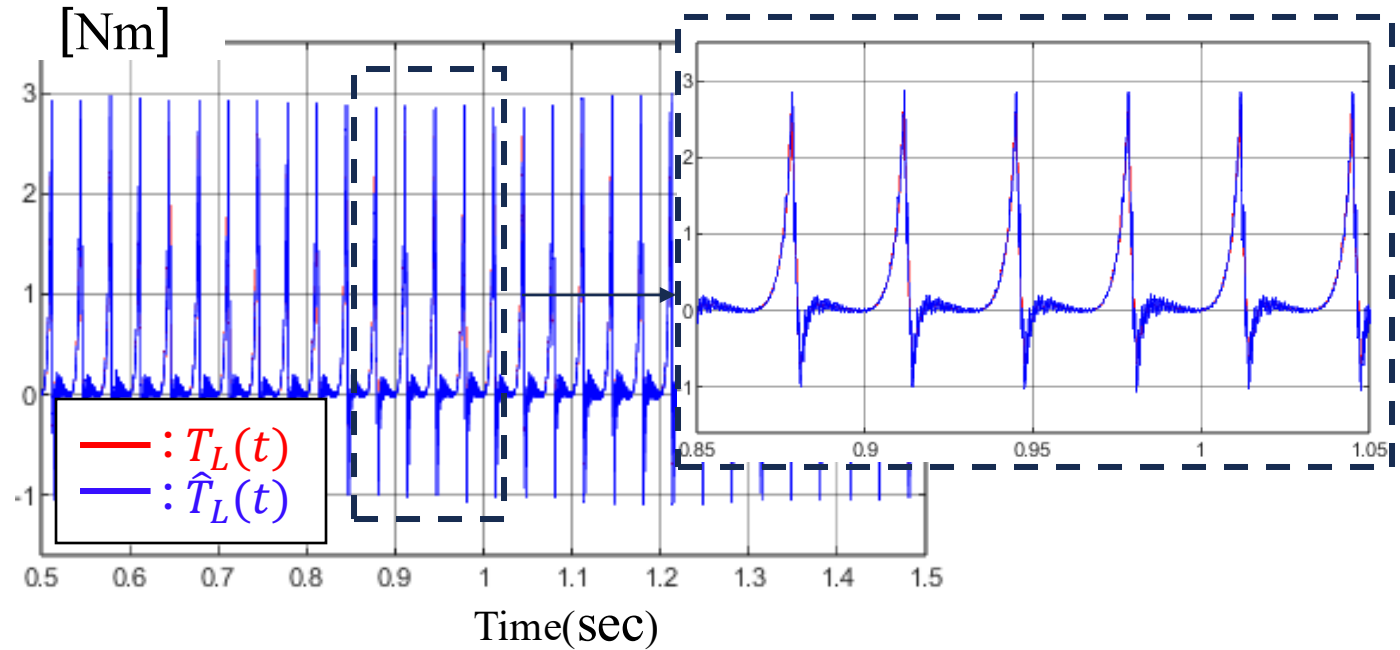
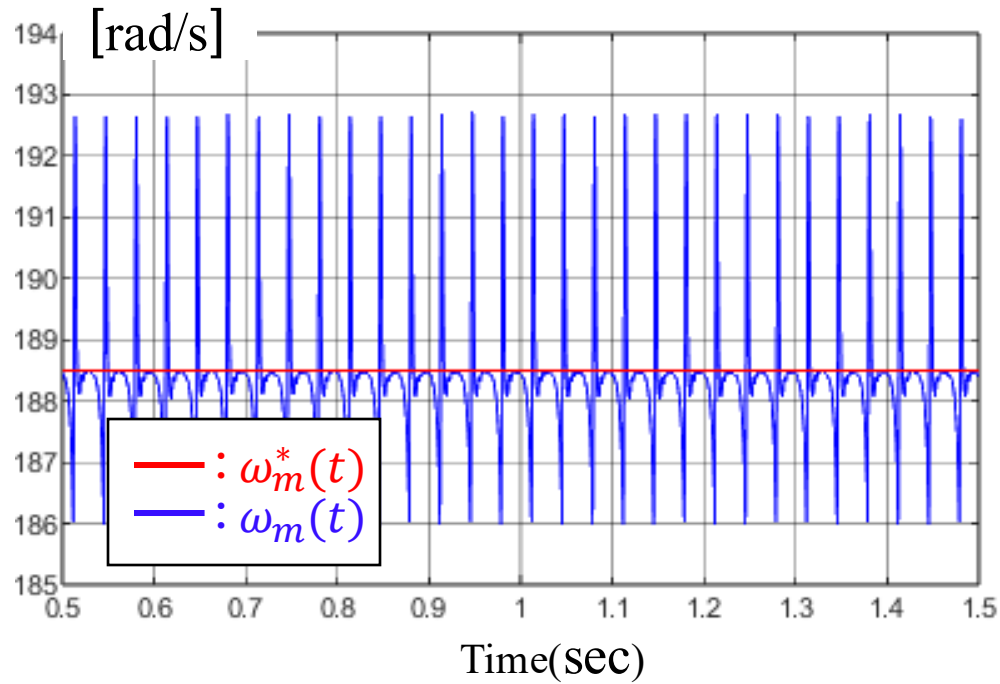
$$\dot{L} \leq -\frac{1}{2} Q \|\tilde{x}\|^2 + \|\tilde{x}\| \underbrace{\left[ P(2W_M - \|\tilde{W}\|) + \eta_1 \alpha \|\tilde{W}\| + \rho_1 \|\tilde{W}\| (W_M + \|\tilde{W}\|) + \eta_2 \alpha (W_M - \|\tilde{W}\|) \|\tilde{V}\| + \rho_2 (V_M - \|\tilde{V}\|) \|\tilde{V}\| \right]}_{:= L_e}$$

$\therefore \dot{L} \leq 0$  if  $\|\tilde{x}\| > 2L_e/Q$   $\rightarrow$   $2L_e/Q$  크기의 추정오차 내로 수렴 가능

- 인공지능 기반 학습 파라미터 튜닝 가이드(상세내용은 부록2 참고)
  - $L_e$  크기를 줄이도록 학습 파라미터( $\eta_1, \eta_2, \rho_1, \rho_2$ )를 튜닝하여 추정오차 크기를 줄임
  - 구체적 조건: 1)  $\rho_1 \geq \left(\frac{\eta_2 \alpha}{2}\right)^2$ , 2)  $\rho_2 \geq 1$ .

# 시뮬레이션을 통한 토크제어 방법 분석

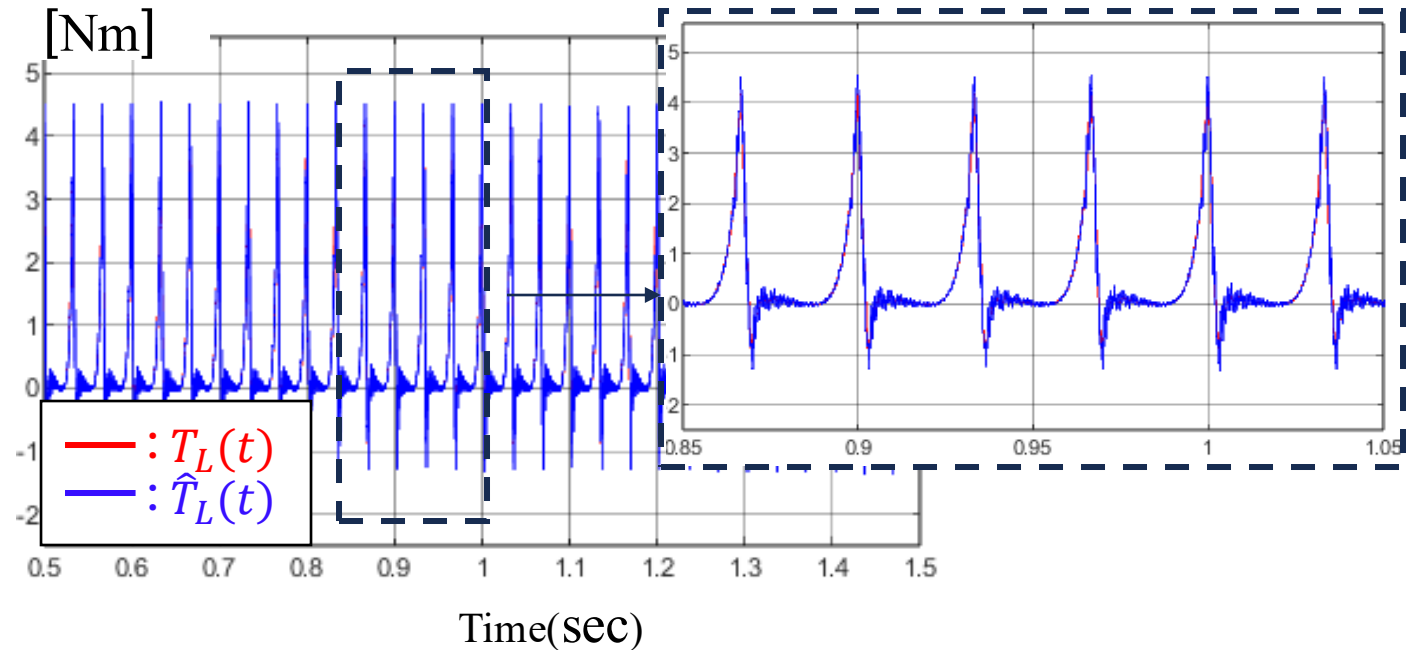
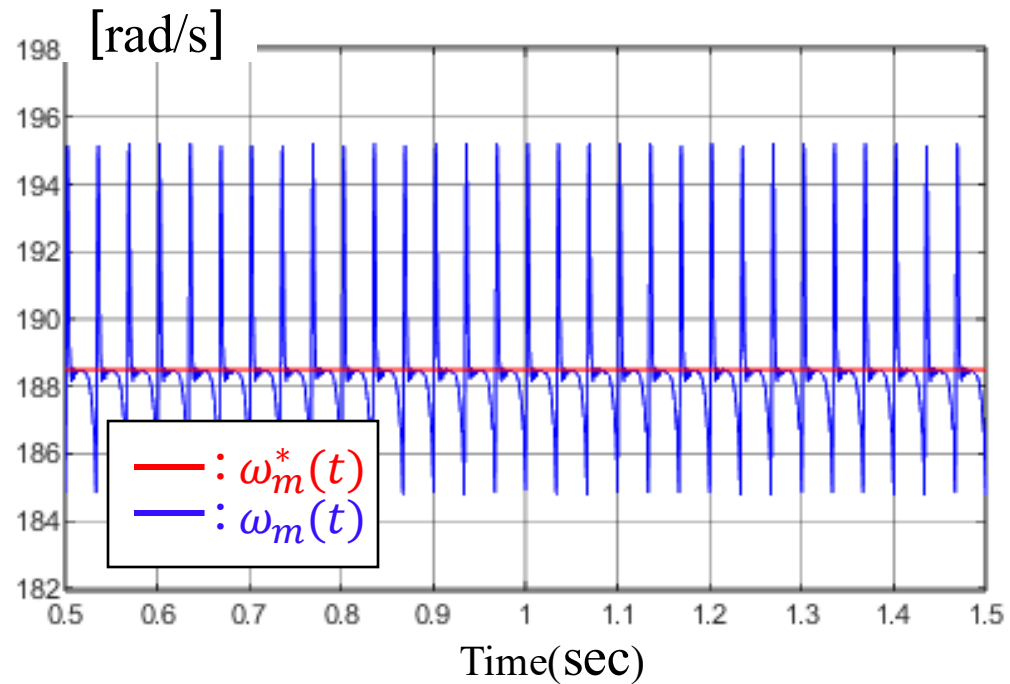
- 시뮬레이션 결과
  - 인공신경망(저부하)



$$RMS_{T_L} = 0.0838, RMS_{\omega} = 0.5868$$

# 시뮬레이션을 통한 토크제어 방법 분석

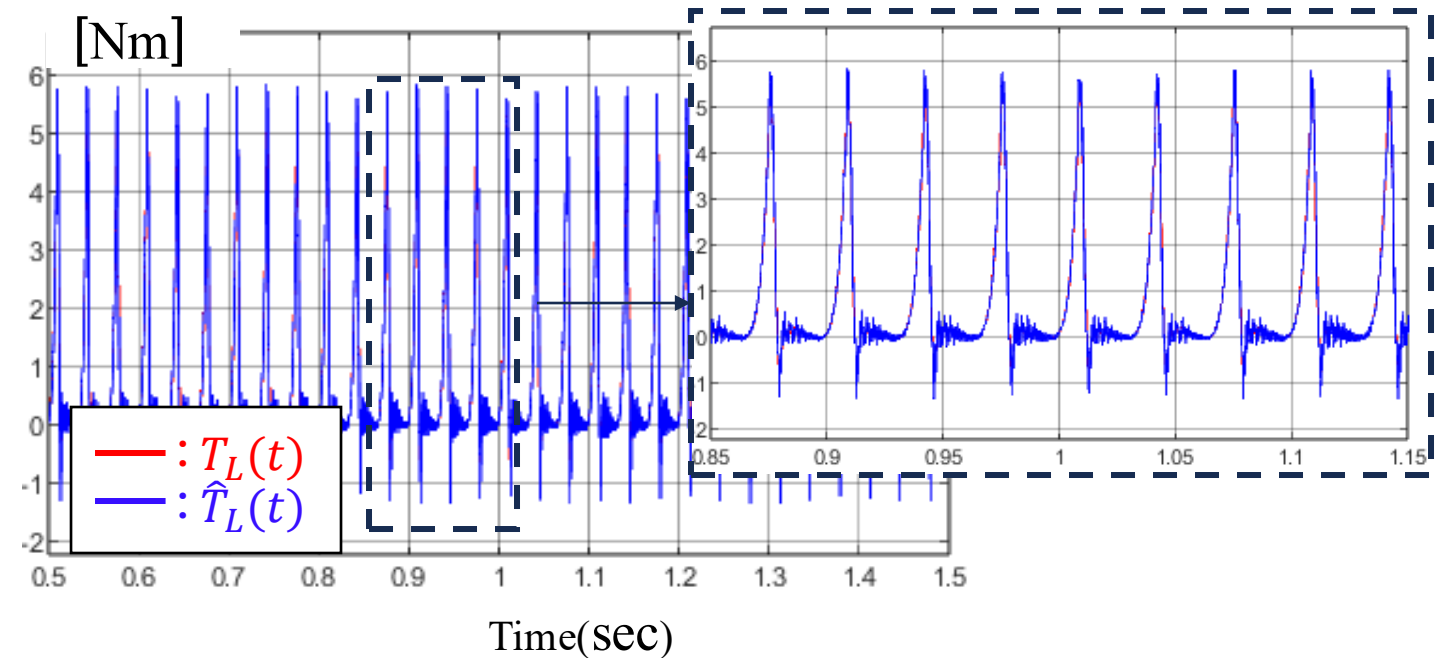
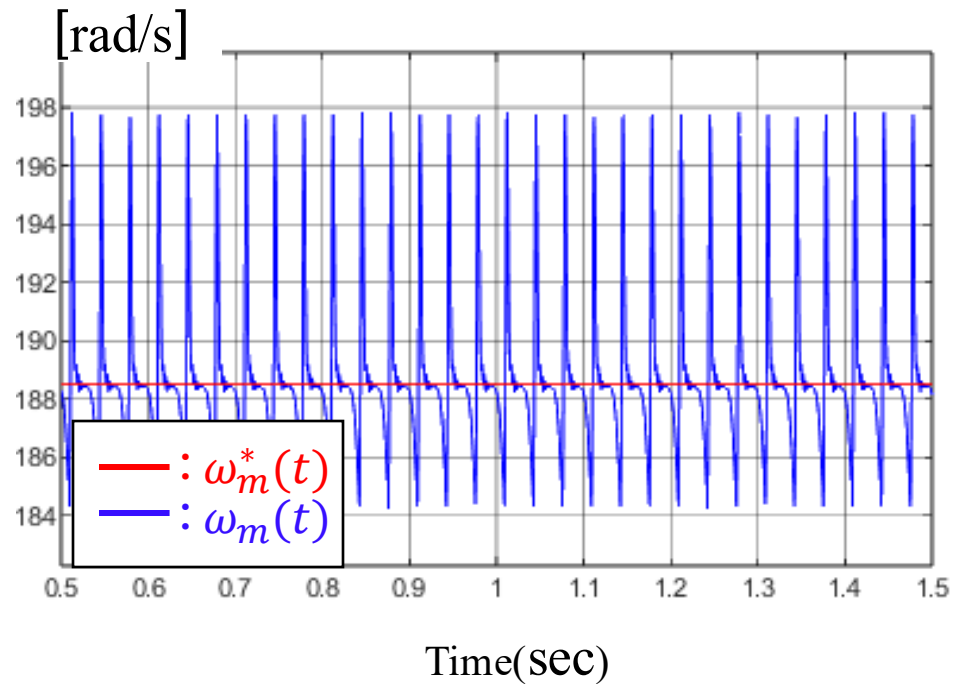
- 시뮬레이션 결과
  - 인공신경망(중부하)



$$RMS_{T_L} = 0.0639, RMS_{\omega} = 1.129$$

# 시뮬레이션을 통한 토크제어 방법 분석

- 시뮬레이션 결과
  - 인공신경망(고부하)



$$RMS_{T_L} = 0.1143, RMS_{\omega} = 1.177$$

## 부록

## 부록1: 모터 전압포화 이슈

### • 기존 DC link 전압( $V_{dc} = 310$ V) 기반 시뮬레이션 결과

- 그림1: 토크지령( $T_e^*$ )은 부하토크를 보상하도록 잘 결정되나 토크( $T_e$ )가 이를 잘 추종 못함
- 그림2: d축 전류( $i_d$ )가 d축 전류지령( $i_d^*$ )을 잘 추종 못함
- 그림 3: q축 전류( $i_q$ )는 q축 전류지령( $i_q^*$ )을 어느정도 잘 추종함
- 그림4: Modulation index가 포화됨 → 전압포화로 인해 d축 전류제어가 불완전함

그림1

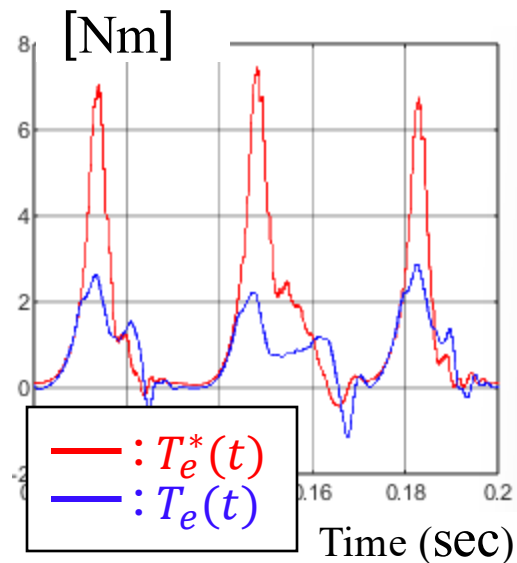


그림2

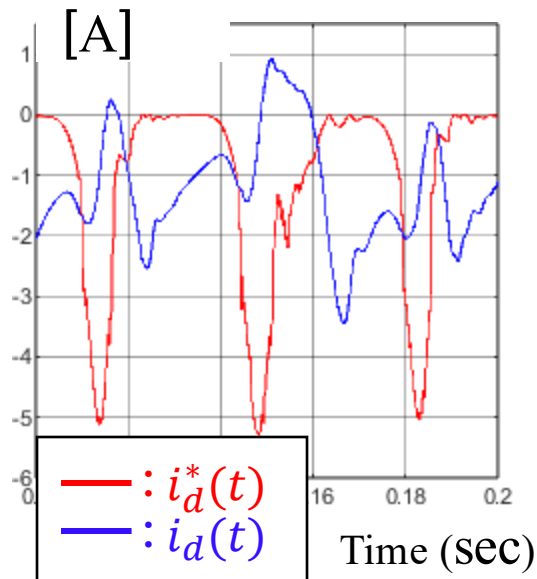


그림3

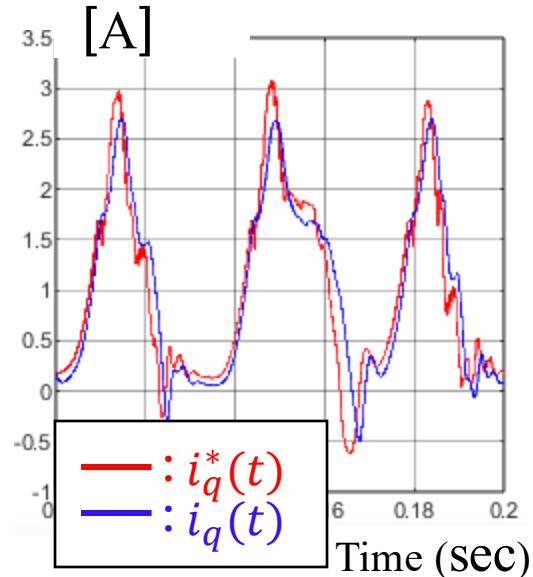
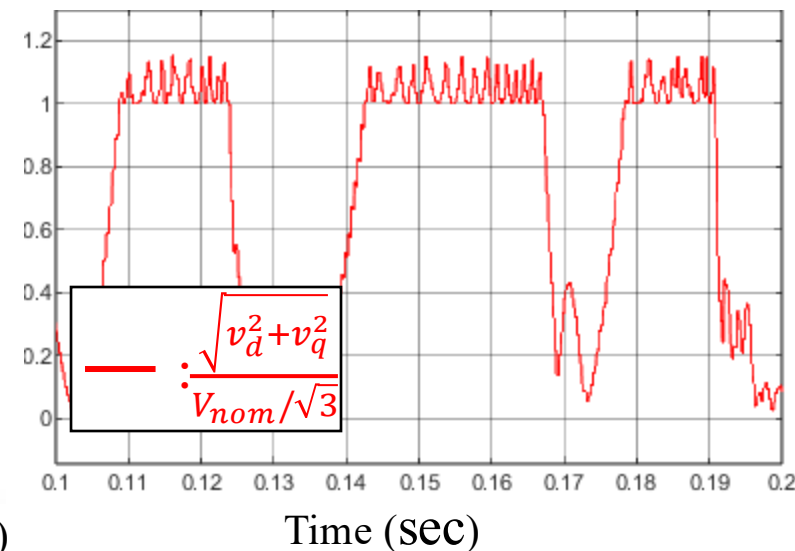


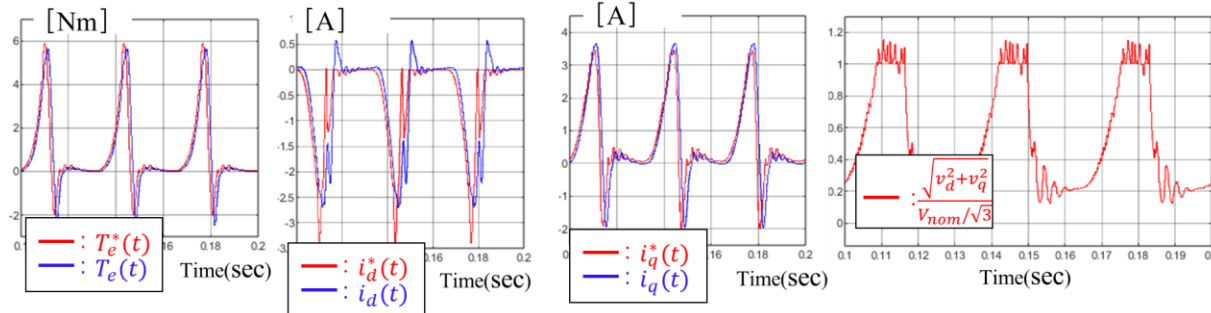
그림4



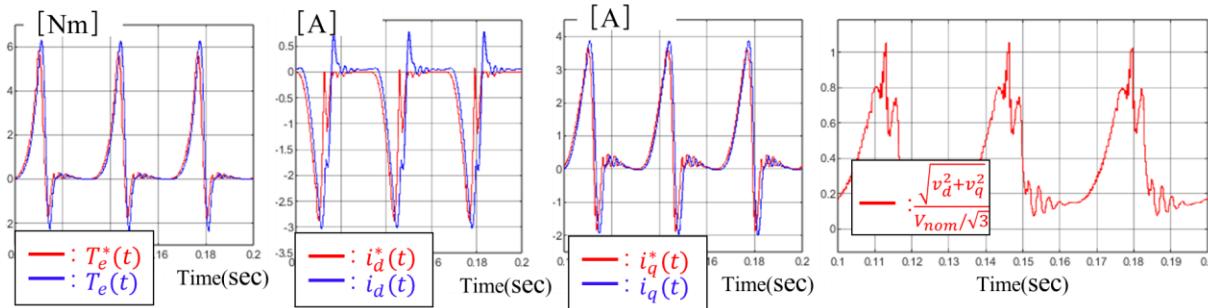
## 부록1: 모터 전압포화 이슈

- DC link 전압 상승 시 기반 시뮬레이션 결과

2배 상승 ( $V_{dc} = 620 \text{ V}$ )



3배 상승 ( $V_{dc} = 930 \text{ V}$ )



- DC link 전압이 상승함에 따라 제어 성능이 개선됨을 보임
- 특히 3배 상승 시 modulation index가 포화되지 않으므로, DC link 전압을 3배로 높여서 시뮬레이션 진행

## 부록2: 인공신경망 학습법칙 및 파라미터 튜닝

### • 인공신경망 학습법칙

상태 변수의 오차를 감소하도록 하는 학습 항과 가중치 행렬의 안정적인 수렴을 위한 지수적 수렴 항으로 구성

$$\dot{\widehat{\mathbf{W}}} = -\eta_1 \frac{\partial J}{\partial \widehat{\mathbf{W}}} - \rho_1 \|\tilde{\mathbf{y}}\| \widehat{\mathbf{W}} \quad \dot{\widehat{\mathbf{V}}} = -\eta_2 \frac{\partial J}{\partial \widehat{\mathbf{V}}} - \rho_2 \|\tilde{\mathbf{y}}\| \widehat{\mathbf{V}} \quad \text{where, } J = \frac{1}{2} \tilde{\mathbf{y}}^T \tilde{\mathbf{y}}$$

학습 항은 Chain rule을 사용하여 전개

$$\begin{aligned} \frac{\partial J}{\partial \widehat{\mathbf{W}}} &= \frac{\partial J}{\partial \tilde{\mathbf{y}}} \frac{\partial \tilde{\mathbf{y}}}{\partial \hat{\mathbf{x}}} \frac{\partial \hat{\mathbf{x}}}{\partial \hat{\mathbf{g}}} \frac{\partial \hat{\mathbf{g}}}{\partial \widehat{\mathbf{W}}} & \text{정적 근사를 통해 계산 } (\dot{\hat{\mathbf{x}}} = 0) & \frac{\partial J}{\partial \widehat{\mathbf{W}}} = \frac{\partial J}{\partial \tilde{\mathbf{y}}} \frac{\partial \tilde{\mathbf{y}}}{\partial \hat{\mathbf{x}}} \frac{\partial \hat{\mathbf{x}}}{\partial \hat{\mathbf{g}}} \frac{\partial \hat{\mathbf{g}}}{\partial \widehat{\mathbf{W}}} = (\tilde{\mathbf{y}}^T \mathbf{C} \mathbf{A}^{-1})^T \hat{\boldsymbol{\sigma}}^T \\ \frac{\partial J}{\partial \widehat{\mathbf{V}}} &= \frac{\partial J}{\partial \tilde{\mathbf{y}}} \frac{\partial \tilde{\mathbf{y}}}{\partial \hat{\mathbf{x}}} \frac{\partial \hat{\mathbf{x}}}{\partial \hat{\mathbf{g}}} \frac{\partial \hat{\mathbf{g}}}{\partial \widehat{\mathbf{V}} \hat{\mathbf{z}}} \frac{\partial \widehat{\mathbf{V}} \hat{\mathbf{z}}}{\partial \hat{\mathbf{z}}} & \frac{\partial \hat{\mathbf{x}}}{\partial \hat{\mathbf{g}}} = -\mathbf{A}^{-1} & \frac{\partial J}{\partial \widehat{\mathbf{V}}} = \frac{\partial J}{\partial \tilde{\mathbf{y}}} \frac{\partial \tilde{\mathbf{y}}}{\partial \hat{\mathbf{x}}} \frac{\partial \hat{\mathbf{x}}}{\partial \hat{\mathbf{g}}} \frac{\partial \hat{\mathbf{g}}}{\partial \widehat{\mathbf{V}} \hat{\mathbf{z}}} \frac{\partial \widehat{\mathbf{V}} \hat{\mathbf{z}}}{\partial \hat{\mathbf{z}}} = \left( \tilde{\mathbf{y}}^T \mathbf{C} \mathbf{A}^{-1} \widehat{\mathbf{W}} (\mathbf{I}_h - \boldsymbol{\Pi}) \right)^T \hat{\mathbf{z}}^T \end{aligned}$$

### • 인공신경망 파라미터 튜닝

수렴성 분석을 통한 파라미터 튜닝 조건

$$\begin{aligned} L_e &= P(2W_M - \|\widehat{\mathbf{W}}\|) + \eta_1 \alpha \|\widehat{\mathbf{W}}\| + \rho_1 \|\widehat{\mathbf{W}}\| (W_M + \|\widehat{\mathbf{W}}\|) + \eta_2 \alpha (W_M - \|\widehat{\mathbf{W}}\|) \|\widehat{\mathbf{V}}\| + \rho_2 (V_M - \|\widehat{\mathbf{V}}\|) \|\widehat{\mathbf{V}}\| \\ &= -\left( \frac{\eta_2 \alpha}{2} \|\widehat{\mathbf{W}}\| - \|\widehat{\mathbf{V}}\| \right)^2 - \left( \rho_1 - \left( \frac{\eta_2 \alpha}{2} \right)^2 \right) \|\widehat{\mathbf{W}}\|^2 - (\rho_2 - 1) \|\widehat{\mathbf{V}}\|^2 + (\eta_1 \alpha + \rho_1 W_M - P) \|\widehat{\mathbf{W}}\| + (\eta_2 \alpha W_M + \rho_2 V_M) \|\widehat{\mathbf{V}}\| + 2PW_M \end{aligned}$$

$$\|\tilde{\mathbf{x}}\| > 2L_e/Q \quad \longrightarrow \quad \rho_1 - \left( \frac{\eta_2 \alpha}{2} \right)^2 \geq 0, \rho_2 - 1 \geq 0 \quad \longrightarrow \quad \eta_1, \eta_2, \rho_1, \rho_2 \text{ 를 조건 내에서 튜닝하여 오차 감소}$$

오차 범위 감소를 위해  $L_e$  값 감소하는 조건